DATASET RESEARCH & INVENTORY

IoT • Edge Computing • Task Offloading • Network Simulation • Reliability

Comprehensive review of exactly five approved research papers

Prepared: 03 November 2026 | Scope: Dataset Research & Inventory only

REVIEW SCOPE	INCLUDED	EXCLUDED
Evidence extraction from five uploaded papers; verification of original dataset repositories; simulation/testbed inventory; comparison and recommendations.	ECW and SMD real-world datasets; P1/P2/P5 synthetic simulation; P4 simulation and hardware testbed.	No Dataset v0 construction, merging, cleaning, feature engineering, or model training.

Important classification: a simulation-generated workload is not a real-world dataset; YOLOv5 is software used to generate image-detection tasks, not the name of the underlying image dataset. The review distinguishes paper-reported facts from repository-verified facts and from information not reported.

Executive Summary

The review identifies two actual public real-world datasets used in Paper 3: ECW (Edge Cloud Workload) and SMD (Server Machine Dataset). Paper 3 trains/evaluates TimesNet on these multivariate time-series sources and passes predicted workload/failure context to a LinUCB offloading policy in a simulated MEC environment. Paper 4 validates its approach through numerical simulation and a physical testbed; it uses YOLOv5 checkpoints and image resolutions to generate image-detection tasks, but does not name or publish the underlying image collection. Papers 1, 2 and 5 use custom simulation and synthetic inputs rather than identified external datasets.

Finding	Evidence-based result
Public real-world datasets identified	ECW and SMD in Paper 3, Section 5.1.3 (PDF p.9).
Public download sources	ECW official GitHub repository; SMD original OmniAnomaly GitHub repository. Direct file links are included in Section 4 and the companion workbook.
Simulation-only papers	P1 Chance-constraint; P2 ESFMTO; P5 RELTO. P1 additionally generates Monte Carlo samples to train ANN surrogates.
Physical testbed	P4: 3 edge servers, 12 NVIDIA Jetson boards, router/base station; YOLOv5-generated image-detection tasks.
Critical limitations	ECW license is not stated in README; paper 3 exact data split details are incomplete; SMD timestamp interval is not specified in original README; P4 image source is undisclosed.

1. Identification of the Five Approved Papers

P1 — Chance constraint-based dependent task offloading for multi-access edge computing under uncertainty

Authors: Xiaomin Jin; Jingbo Wang; Zhongmin Wang; Yanping Chen
Publication: Applied Soft Computing, Vol. 201, Part C, article 115710 | Date/year: 2026-09
DOI: 10.1016/j.asoc.2026.115710
Experimental type: Simulation only; generated Monte Carlo/ANN training samples

Open publisher / DOI record

P2 — ESFMTO: A reliable task offloading strategy based on edge server failure model in IIoT

Authors: Yubin Yang; Yan Chen; Ningjiang Chen; Juan Chen
Publication: Ad Hoc Networks, Vol. 176, article 103887 | Date/year: 2025-09-01
DOI: 10.1016/j.adhoc.2025.103887
Experimental type: Custom IIoT failure simulation only

Open publisher / DOI record

P3 — Forecast-driven task offloading for reliable and adaptive mobile edge computing

Authors: Ting Li; Yinan Mi; Kai Yang
Publication: Journal of Network and Computer Applications, Vol. 251, article 104494 | Date/year: 2026-07
DOI: 10.1016/j.jnca.2026.104494
Experimental type: Two real time-series datasets (ECW, SMD) + simulated MEC/offloading/failure environment

Open publisher / DOI record

P4 — Quality of Experience and Reliability-Aware Task Offloading and Scheduling for Multi-User Mobile-Edge Computing Systems

Authors: Junlong Zhou; Xiangpeng Hou; Yue Zeng; Peijin Cong; Weiming Jiang; Song Guo
Publication: IEEE Transactions on Services Computing, Vol. 18, Issue 3, pp. 1683–1696 | Date/year: 2025-03-18
DOI: 10.1109/TSC.2025.3552338
Experimental type: Numerical simulation + physical testbed; YOLOv5-generated workloads

Open publisher / DOI record

P5 — RELTO: A reliability-oriented DRL approach with context-aware adaptive reward weighting for multi-objective task offloading in MEC

Authors: Anam Nasir; Xiang He; Teng Wang; Haomai Shi; Zhongjie Wang
Publication: Ad Hoc Networks, Vol. 181, article 104065 | Date/year: 2026-02-01
DOI: 10.1016/j.adhoc.2025.104065
Experimental type: Custom MEC simulation only; article states no data was used

Open publisher / DOI record

2. Dataset Inventory

Only sources actually used in experiments are classified as datasets below. Mention of other datasets in related work is not counted. Paper 4's YOLOv5-generated tasks are listed separately as a testbed workload asset, not as an independently published dataset.

P3 — ECW (Edge Cloud Workload)

Original source: Huang et al. (2023), real logs from a leading/commercial multi-tenant edge-cloud service provider; source company anonymized

Publication year: 2023 (original dataset paper)

Version: Repository main branch; ECW-08 and ECW-09 releases; no semantic version number stated

Dataset size / shape: ECW-08: 797 × 720 × 16; ECW-09: 1,022 × 720 × 16

Number of records: 573,840 server-hour observations (797×720) + 735,840 (1,022×720) = 1,309,680 server-hour observations; each has 16 features

Time period covered: Aug 2022 (ECW-08) and Sep 2022 (ECW-09); repository describes overall release range Aug–Oct 2022; Paper 3 text says Aug–Oct

Features / variables: 16 columns: bw_upload; hour; day; week; province; bandwidth_type; nat_type; isp; billing_rule; upbandwidth; upbandwidth_base; cpu_num; memory_size; disk_size; test_sat; loss_sat

Data format: Preprocessed NumPy .npy; derivative samples .pkl

How the paper used it: Paper 3 uses ECW to train/evaluate TimesNet forecasting of edge workload (upload-bandwidth/load dynamics); normalized features are restored for system-level evaluation; forecasts become context for LinUCB task offloading

Training / testing / evaluation purpose: Forecast training/forecast evaluation; paper reports two independent training runs and validation but does not fully document an explicit train/validation/test partition for ECW

Data type: Real-world operational telemetry, not synthetic

Availability and license: Public GitHub repository. README says values normalized to min/max for privacy. No explicit dataset license identified in repository README; obtain permission/terms from authors before redistribution or commercial use.

Exact paper location: Paper 3, Section 5.1.3, PDF p.9; ECW README, dataset description and Table 1

Verification notes: Paper describes Aug–Oct, but the main public repo lists monthly ECW-08 and ECW-09 plus three derivative datasets. Do not infer an October monthly tensor from the listed files. File byte sizes are not specified in README.

Official repository: https://github.com/hsy23/ECWDataset

- ECW-08 direct file
- ECW-09 direct file
- Application-switch sample
- New-application sample
- New-infrastructure sample

P3 — SMD (Server Machine Dataset)

Original source: Collected by the OmniAnomaly authors from a large Internet company; 28 machine entities grouped as machine-group-index

Publication year: 2019 original OmniAnomaly publication/release

Version: Original ServerMachineDataset in OmniAnomaly master repository; no numbered version stated

Dataset size / shape: 28 machines × 38 channels; 5-week benchmark

Number of records: 708,405 training rows + 708,420 test rows = 1,416,825 aggregate rows across 28 machine entities; per-machine split is retained

Time period covered: Five weeks; original README does not specify a timestamp interval; some third-party mirrors state 1 minute, but this is not confirmed in the original README

Features / variables: 38 multivariate server-monitoring metrics per machine; test_label provides anomaly flag per time step; interpretation_label maps dimensions contributing to anomalies. Exact 38 field names are not enumerated in Paper 3 or the original README.

Data format: Per-machine numeric text files (train, test, test_label, interpretation_label); processed artifacts may be generated by preprocessing script

How the paper used it: Paper 3 uses SMD anomaly labels as supervision to construct a failure-event indicator and failure-intensity time series; TimesNet forecasts failure dynamics; predicted failure rate is fed to MEC reliability/offloading model

Training / testing / evaluation purpose: Original source provides per-machine train/test and anomaly labels. Paper 3 does not specify its own complete downstream split protocol in the dataset paragraph.

Data type: Real-world server telemetry / anomaly benchmark

Availability and license: Public GitHub repository. Do not assume repository software license automatically settles rights to underlying company telemetry; verify dataset reuse terms. A separate CC-BY-4.0 conversion exists on Hugging Face but is a derivative format, not the original paper source.

Exact paper location: Paper 3, Section 5.1.3, PDF p.9; OmniAnomaly README, Dataset Information and SMD sections

Verification notes: Paper says five weeks; exact sample interval should be checked from original files/metadata, not inferred from third-party mirrors.

Original repository: https://github.com/NetManAIOps/OmniAnomaly

Repository ZIP download: https://github.com/NetManAIOps/OmniAnomaly/archive/refs/heads/master.zip

P4 — YOLOv5-generated image-detection task instances (not a published dataset)

Original source: Generated in the authors' physical testbed using YOLOv5; underlying image collection/provider is not identified in the paper

Publication year: Paper published 2025; YOLOv5 checkpoint/software version not stated

Version: Four checkpoint variants named YOLOv5n, YOLOv5s, YOLOv5m, YOLOv5l; exact software release not specified

Dataset size / shape: No dataset size reported

Number of records: No record/image count reported

Time period covered: Not reported

Features / variables: Image-detection inputs; checkpoint model and image resolution are varied; benchmark resolutions 640, 960, 1280, 1600 (Table IV)

Data format: Image inputs and task execution measurements; exact input file format and released logs not stated

How the paper used it: Creates testbed tasks executed locally on mobile devices or offloaded to edge servers; compares latency/utility under real hardware execution

Training / testing / evaluation purpose: Physical testbed evaluation, not a published ML training dataset

Data type: Testbed-generated experimental workload; no separate data repository or data license identified

Availability and license: No downloadable task dataset or image-data license identified in the paper; YOLOv5 software license is separate from the underlying images

Exact paper location: Paper 4, PDF pp.9–10 (IEEE pp.1691–1692), Testbed Experiment Setup, Tables III–IV, Fig.5

Verification notes: YOLOv5 is the detector/workload-generation software, not the image dataset. Do not list the COCO dataset unless the paper explicitly confirms it; it does not.

YOLOv5 official software repository: https://github.com/ultralytics/yolov5

3. Simulation and Testbed Inventory

For simulation-only studies, the simulator is identified as custom when no named simulator (e.g., NS-3, OMNeT++) is stated. Missing duration, episode count, random seeds or replication counts are marked as not reported rather than estimated.

P1 — Chance constraint-based dependent task offloading for multi-access edge computing under uncertainty

Environment / software: Custom numerical simulation; Python 3.8; PyTorch 2.2; fully connected ANN (3 hidden layers: 500, 200, 50)

Topology: Cloud–Edge–End architecture; local mobile terminal, edge, cloud; 3 wireless network interfaces; task dependency DAG

Task generation / workload: 30 tasks per application; task attributes uniformly randomly sampled from Table 3 ranges; tasks randomly permuted to establish topological order; directed dependency considered only from earlier to later task with probability ρ=0.8; each task has at least one input dependency from a previous task

Compute and task parameters: Mobile terminal 7 GHz; edge allocation 15 GHz; cloud allocation 30 GHz; input size 500–4,000 KB; workload 1,000–10,000 cycles (as printed in Table 3); deadline 700–1,000 ms; output 40–100 KB; cache 5,500 KB; local execution power 0.8 W; idle power 0.4 W

Network parameters: 3 wireless networks; uplink bandwidth 8–16 MHz; downlink 10–20 MHz; uplink power 0.3–0.5 W; downlink 0.1–0.2 W; bandwidth multiplied by Ω~Beta(2,8); privacy risk threshold 1.8

Paper location: PDF pp.14–16; Section 5.1; Table 3; Algorithm 7

Reporting notes: ANN training samples are generated by Monte Carlo until a required quantity is met, but target quantity is not stated. Simulation duration/episode count and number of independent runs are not stated. Data availability says “upon request.”

P2 — ESFMTO: A reliable task offloading strategy based on edge server failure model in IIoT

Environment / software: Custom IIoT edge-server/container failure simulator; SAC-BNN / Soft Actor-Critic + Bayesian neural network; no named simulator platform or code repository identified

Topology: Industrial manufacturing/production-line scenario; m edge servers, each with c containers; n users; 20 edge servers and 50–70 users in Table 2; each user generates one task per time slot

Task generation / workload: At each slot, every industrial user generates one task; tasks are assigned to an edge server; task size varied 1–5 MB in evaluation; hardware and container failures/recovery modeled as stochastic events (exponential failure/recovery process described in model)

Compute and task parameters: CPU frequency parameter 2 GHz; edge server hardware failure rate 0.02–0.05; container failure rate 0.03–0.09; hardware recovery rate 2; container recovery rate 3; confidence level 75–95%

Network parameters: Channel gain 40 dB; noise power 10^-10 W; link throughput computed using Shannon capacity; transmission, queueing and computation delays modeled

Paper location: PDF pp.9–12; Section 5.1; Table 2; task-size experiment Section 5.2

Reporting notes: No public external dataset. Numeric time horizon/slot duration, exact number of episodes/runs, and container count c are not explicitly provided in Table 2. Data availability says “on request.”

P3 — Forecast-driven task offloading for reliable and adaptive mobile edge computing

Environment / software: Unified custom three-tier MEC simulation; Python/PyTorch 2.0.1; TimesNet forecaster + LinUCB online contextual bandit

Topology: Default: 10 user devices, 5 edge servers, remote cloud; action set local + 5 ES + cloud; simulated three-tier architecture

Task generation / workload: Forecasts are learned from ECW and SMD real telemetry. MEC offloading tasks and system dynamics are evaluated in simulation. Task-arrival rate is increased; user population and edge-server count are varied. 30 random seeds and ITER=2,000 for extended scalability experiments; 5 seeds for reported context ablation

Compute and task parameters: UD CPU 0.8 GHz; ES CPU 8–12 GHz; cloud CPU 40 GHz; TimesNet input window 96, warm-up 48, forecast horizon 96; 5 periodic branches; 6 convolution branches; embedding/intermediate dimensions 32; 2 TimesBlocks; max 100 epochs; batch 16

Network parameters: Bandwidth 30 MHz; transmit power 0.25 W; noise PSD 10^-9 W/Hz; reliability θ=0.5; bit error rate 5×10^-7; baseline failure intensity 6.364×10^-2; same forecasted risk trajectory shared across ESs for controlled comparison

Paper location: PDF pp.8–11; Sections 5.1.1–5.1.3; Table 2; Fig.4; Section 5.2.3

Reporting notes: Mixed case: real traces are forecasting inputs; failure process and MEC/offloading execution are simulated. Paper Data Availability: “Data will be made available on request.”

P4 — Quality of Experience and Reliability-Aware Task Offloading and Scheduling for Multi-User Mobile-Edge Computing Systems

Environment / software: Numerical simulation + physical hardware testbed; YOLOv5 for image-detection benchmark task generation; no named network simulator

Topology: Simulation: 1 BS + 3 ES; three systems with 20, 35, 50 mobile devices. Testbed: 3 edge servers, 12 NVIDIA Jetson boards, 1 router acting as BS; MDs connect wirelessly, ESs via Ethernet

Task generation / workload: Simulation task parameters sampled uniformly: input data 200–1,000 KB; execution cycles 500–2,500 Megacycles; vulnerability factor [0,1]; user latency/energy preferences [0,1] with sum 1. Testbed tasks generated by varying YOLOv5 checkpoint and image resolution

Compute and task parameters: Mobile-device CPU 1.0–1.2 GHz; three ES capacity profiles: [8,10,12] GHz, [14,16,18] GHz, [20,22,24] GHz; testbed Jetson boards include Orin Nano, Orin NX, AGX Orin; three Dell servers as ESs

Network parameters: BS bandwidth 15, 25, 35 MHz; mobile transmit power uniform [0.1,0.5] W; background noise −100 dBm; energy coefficient 5×10^-27; reliability threshold 0.9

Paper location: PDF pp.9–10 (IEEE pp.1691–1692); Section VIII-A; Tables I–IV; Fig.5

Reporting notes: Testbed Table III: Orin Nano CPU frequencies 1510.4, 1267.2, 960.0, 652.8 MHz; Orin NX 1984, 1728, 1420.8, 883.2 MHz; AGX Orin 2201.6, 1958.4, 1651.2, 1190.4 MHz. Edge servers: Dell P5820 i9-10900X 3500 MHz; Dell P5820 i7-13700KF 3400 MHz; Dell T640 Xeon Silver 4210R 2000 MHz. Table IV: YOLOv5n/s/m/l at 640/960/1280/1600 resolutions.

P5 — RELTO: A reliability-oriented DRL approach with context-aware adaptive reward weighting for multi-objective task offloading in MEC

Environment / software: Custom MEC simulation environment built with Python 3.6 and Torch/PyTorch 1.9.1; PPO-based RELTO; NVIDIA RTX 3080; no named network simulator

Topology: 5,000 × 5,000 m area; 50–250 users; 4–32 fixed edge servers; SINR-based communication links

Task generation / workload: Each user generates four tasks with varying computation, time and memory requirements; task intervals uniformly distributed; service utilization ρ=0.8–0.95; mean service rate normally distributed around 0.5 tasks/ms; arrival rate a=ρs

Compute and task parameters: Local CPU 10^8 cycles/s; edge CPU 10^7–10^10 cycles/s; each service request 10 million CPU cycles; local energy 10^-8 J/cycle; edge energy 10^-9 J/cycle

Network parameters: Bandwidth 20–500 MHz; SINR with path loss and thermal noise; transmission failure λ and computation failure ε each tested at 0.02, 0.04, 0.06, 0.08

Paper location: PDF pp.12–13; Section 5.1; Table 3; Data availability statement

Reporting notes: PPO hyperparameters in Table 3: learning rate 0.0001; discount factor 0.99; batch 128; clip 0.2; entropy coefficient 0.01; GAE 0.95; feature-attention layers/heads/embedding 3/8/128; reward-attention layers/heads/embedding 1/4/128; dropout 0.1. No external dataset: paper explicitly states “No data was used for the research described in the article.” Simulation duration, random seeds and number of independent replications are not stated.

4. Dataset Source References and Download Guide

The two primary dataset download routes are the original public repositories below. The repository pages are the authoritative landing pages; direct file links are included where the file path is visible in the repository listing.

ECW repository: https://github.com/hsy23/ECWDataset — Contains ECW_08.npy, ECW_09.npy and derivative .pkl files. Repository README documents source, shape, hourly granularity and fields.

ECW-08 direct download: https://raw.githubusercontent.com/hsy23/ECWDataset/main/ECW_08.npy — NumPy .npy file for August 2022 ECW series.

ECW-09 direct download: https://raw.githubusercontent.com/hsy23/ECWDataset/main/ECW_09.npy — NumPy .npy file for September 2022 ECW series.

SMD / OmniAnomaly repository: https://github.com/NetManAIOps/OmniAnomaly — Original SMD repository; ServerMachineDataset folder includes per-machine train/test and labels.

SMD full repository ZIP: https://github.com/NetManAIOps/OmniAnomaly/archive/refs/heads/master.zip — Downloads repository archive including dataset folder.

ECW original KDD paper: https://doi.org/10.1145/3580305.3599453 — Huang et al. (2023), One for All: Unified Workload Prediction for Dynamic Multi-tenant Edge Cloud Platforms.

SMD original KDD paper: https://doi.org/10.1145/3292500.3330680 — Su et al. (2019), Robust Anomaly Detection for Multivariate Time Series through Stochastic Recurrent Neural Network.

YOLOv5 software: https://github.com/ultralytics/yolov5 — Software only; not the image dataset used in the testbed.

5. Dataset Comparison and Relevance

Source	IoT	Edge	Workload	Network conditions	Task offloading	Reliability	Strengths / limitations
ECW	High	Very high	Very high	Moderate	Moderate	Real operational edge-cloud workload; includes upload bandwidth and server hardware/network attributes. No per-task execution/offloading outcomes, latency labels or task DAGs.	
SMD	High	Moderate	High for server telemetry	Low	Very high for anomaly evidence	Real 28-machine telemetry and anomaly labels; not a network packet trace and not a task-offloading dataset.	
P1 synthetic tasks	High	High	High	Very high	Moderate	DAG dependencies, task input/workload/deadline, caching, CMT and stochastic bandwidth; all synthetic and reproducibility depends on random generation.	
P2 synthetic IIoT failure model	Very high	High	Moderate	High	Very high	Explicit hardware/container failure and recovery; no real industrial failure logs.	
P4 testbed	High	Very high	High task benchmark	Moderate	High	Real hardware and task execution evidence; source images and raw logs not released/identified.	
P5 synthetic MEC	High	Very high	Very high	Very high	Very high	Broad bandwidth/CPU/utilization/failure ranges; no external data, fully simulated.	

Qualitative ratings are analyst judgments based on the paper's use case and variables; they are not measured scores or claims made by the authors.

6. Recommendations for Initial Dataset v0 (No Dataset Construction)

Priority	Candidate	Why it is relevant	Compatibility limits / action required
1	ECW	Real edge-cloud upload-bandwidth workload plus	Does not contain task-level offloading outcomes, task DAGs or execution

		server/network/hardware attributes; strongest public source for edge workload dynamics.	latency. Confirm license and exact sampling/time-index semantics.
2	SMD	Real multivariate server telemetry with anomaly labels; useful for server-health and failure/reliability signals.	Not a packet/network trace or MEC task dataset. Need a defensible mapping from anomaly labels to edge-server failure intensity and preserve per-machine identities.
3	P4 testbed records (request authors)	Potentially valuable real hardware measurements: device/server configuration, task input, latency, utility and execution outcomes.	Not publicly released/identified. Ask for image source/license, raw logs and YOLOv5 version/checkpoints.
4	P1/P2/P5 simulation specifications	Complement real data with dependent tasks, container failures, task arrival, bandwidth, queueing and failure scenarios.	Keep synthetic scenarios separately labeled; do not present generated samples as real-world observations.

7. Verification Gaps and Questions for Authors

- **P3 / ECW:** Confirm the exact tensor files and sampling/index semantics used in the paper; repository lists Aug/Sep tensors though paper describes Aug–Oct. Obtain explicit reuse permission/license. (High priority)
- **P3 / SMD:** Confirm preprocessing from 28 machines into failure-event/failure-intensity sequence, temporal alignment, and exact split used for TimesNet. (High priority)
- **P4 / testbed:** Request underlying image dataset name/license, YOLOv5 software version, raw task metadata, per-run latency/energy/completion logs, and hardware measurement protocol. (High priority)
- **P1:** Request ANN Monte Carlo generated training samples, target sample quantity, random seeds and complete simulation scripts. (Medium priority)
- **P2:** Request simulator source, task arrival/size distributions, time-slot duration, number of containers, number of episodes/runs, and raw outcomes. (Medium priority)
- **P5:** Request code, random seeds, exact distribution parameters, experiment duration and raw logs. (Medium priority)

8. Source and Paper Traceability Register

Ref.	Source	URL	What it verifies / caveat
R1	ECW official repository	https://github.com/hsy23/ECWDataset	Official dataset repository; README documents provenance, monthly tensors, shapes, features, normalization and data format | Public; no explicit dataset license found in README | Paper 3 PDF p.9; repository README
R2	ECW-08 direct raw file	https://raw.githubusercontent.com/hsy23/ECWDataset/main/ECW_08.npy	Direct NumPy file download | Public file; reuse terms still need confirmation | ECW repository file listing
R3	ECW-09 direct raw file	https://raw.githubusercontent.com/hsy23/ECWDataset/main/ECW_09.npy	Direct NumPy file download | Public file; reuse terms still need confirmation | ECW repository file listing
R4	ECW app-switch sample	https://raw.githubusercontent.com/hsy23/ECWDataset/main/ECW_switch.pkl	Derivative workload series for application switching | Public file; no separate license statement identified | ECW repository file listing and README
R5	ECW new-app sample	https://raw.githubusercontent.com/hsy23/ECWDataset/main/ECW_newapp.pkl	Derivative workload series for previously unseen applications | Public file; no separate license statement identified | ECW repository file listing and README
R6	ECW new-infrastructure sample	https://raw.githubusercontent.com/hsy23/ECWDataset/main/ECW_newmac.pkl	Derivative workload series for new infrastructure; repository filename is ECW_newmac.pkl (README label says New-Infras.) | Public file; no separate license statement identified | ECW repository file listing and README
R7	ECW original publication	https://doi.org/10.1145/3580305.3599453	Huang et al., "One for All: Unified Workload Prediction for Dynamic Multi-tenant Edge Cloud Platforms," KDD 2023, pp.788–797 | Publication metadata and dataset provenance | ECW repository README
R8	SMD original repository (OmniAnomaly)	https://github.com/NetManAIOps/OmniAnomaly	Original repository; contains ServerMachineDataset; README documents 28 entities, 38 dimensions, 5 weeks, split sizes and labels | Public repository; verify data-specific reuse terms | Paper 3 PDF p.9; OmniAnomaly README
R9	SMD repository ZIP download	https://github.com/NetManAIOps/	Download full repository ZIP, including

		OmniAnomaly/archive/refs/heads/master.zip	ServerMachineDataset folder | Public archive; includes source code and dataset files | OmniAnomaly repository
R10	SMD original paper	https://doi.org/10.1145/3292500.3330680	Su et al. (2019), "Robust Anomaly Detection for Multivariate Time Series through Stochastic Recurrent Neural Network," KDD 2019 | Original dataset/method provenance | OmniAnomaly README
R11	YOLOv5 software repository	https://github.com/ultralytics/yolov5	Official YOLOv5 software used for generating image-detection task instances in Paper 4 | Software source, not the image dataset; software license does not license test images | Paper 4 PDF p.10, Table IV
R12	Paper 1 DOI	https://doi.org/10.1016/j.asoc.2026.115710	Paper metadata and source article | No external dataset; generated ANN samples described in Algorithm 7 | Paper 1 PDF pp.14–16
R13	Paper 2 DOI	https://doi.org/10.1016/j.adhoc.2025.103887	Paper metadata and source article | Custom IIoT simulation; no external dataset identified | Paper 2 PDF pp.9–12
R14	Paper 3 DOI	https://doi.org/10.1016/j.jnca.2026.104494	Paper metadata and source article | ECW + SMD + simulated MEC; data availability says on request | Paper 3 PDF pp.8–11 and p.15
R15	Paper 4 DOI	https://doi.org/10.1109/TSC.2025.3552338	Paper metadata and source article | Simulation + hardware testbed; YOLOv5 task benchmark | Paper 4 PDF pp.9–10
R16	Paper 5 DOI	https://doi.org/10.1016/j.adhoc.2025.104065	Paper metadata and source article | Custom simulation; no data used statement | Paper 5 PDF pp.12–13

9. Methodology, Assumptions and Limitations

- Exactly the five PDFs in the uploaded research archive were reviewed. No additional papers were substituted for the approved set.
- An external dataset is counted only where the paper identifies it as an experimental input. A simulator's generated tasks are recorded under Simulation Inventory, not as real-world datasets.
- ECW metadata was checked against the official ECWDataset GitHub README and visible file list. The README reports normalized data for privacy and does not provide an explicit dataset license.
- SMD metadata was checked against the original OmniAnomaly README. The original README gives 28 entities, 38 dimensions, 708,405 training rows, 708,420 testing rows and five-week duration. It does not specify an exact timestamp interval.
- Paper 3 states ECW logs cover August to October 2022, while the public repository's primary monthly tensors listed are ECW-08 and ECW-09. The report preserves this distinction and does not invent an October tensor.
- Paper 4 uses YOLOv5 checkpoints (n/s/m/l) and image resolutions (640/960/1280/1600) to generate task instances. The underlying image collection is not named in the paper and must not be assumed to be COCO.
- No Dataset v0 was assembled. No data cleaning, normalization, merging, model training or new experiment was performed as part of this inventory.

References

P1. Xiaomin Jin; Jingbo Wang; Zhongmin Wang; Yanping Chen (2026). Chance constraint-based dependent task offloading for multi-access edge computing under uncertainty. Applied Soft Computing, Vol. 201, Part C, article 115710. DOI: 10.1016/j.asoc.2026.115710

P2. Yubin Yang; Yan Chen; Ningjiang Chen; Juan Chen (2025). ESFMTO: A reliable task offloading strategy based on edge server failure model in IIoT. Ad Hoc Networks, Vol. 176, article 103887. DOI: 10.1016/j.adhoc.2025.103887

P3. Ting Li; Yinan Mi; Kai Yang (2026). Forecast-driven task offloading for reliable and adaptive mobile edge computing. Journal of Network and Computer Applications, Vol. 251, article 104494. DOI: 10.1016/j.jnca.2026.104494

P4. Junlong Zhou; Xiangpeng Hou; Yue Zeng; Peijin Cong; Weiming Jiang; Song Guo (2025). Quality of Experience and Reliability-Aware Task Offloading and Scheduling for Multi-User Mobile-Edge Computing Systems. IEEE Transactions on Services Computing, Vol. 18, Issue 3, pp. 1683–1696. DOI: 10.1109/TSC.2025.3552338

P5. Anam Nasir; Xiang He; Teng Wang; Haomai Shi; Zhongjie Wang (2026). RELTO: A reliability-oriented DRL approach with context-aware adaptive reward weighting for multi-objective task offloading in MEC. Ad Hoc Networks, Vol. 181, article 104065. DOI: 10.1016/j.adhoc.2025.104065

1. Huang, S., Wang, Z., Zhang, H., Wang, X., Zhang, C., & Wang, W. (2023). One for All: Unified Workload Prediction for Dynamic Multi-tenant Edge Cloud Platforms. Proceedings of ACM SIGKDD 2023, 788–797. https://doi.org/10.1145/3580305.3599453
2. Su, Y., Zhao, Y., Niu, C., Liu, R., Sun, W., & Pei, D. (2019). Robust Anomaly Detection for Multivariate Time Series through Stochastic Recurrent Neural Network. Proceedings of ACM SIGKDD 2019. https://doi.org/10.1145/3292500.3330680
3. ECWDataset official repository: https://github.com/hsy23/ECWDataset
4. OmniAnomaly / SMD original repository: https://github.com/NetManAIOps/OmniAnomaly
5. Ultralytics YOLOv5 repository: https://github.com/ultralytics/yolov5

Arabic Edition | النسخة العربية

جرد مصادر البيانات والمحاكاة لأبحاث إنترنت الأشياء والحوسبة الطرفية وتفريغ المهام

مراجعة خمسة أبحاث محددة فقط — تاريخ الإعداد: 3 نوفمبر 2026

ملخص تنفيذي

تُظهر المراجعة وجود مجموعتي بيانات حقيقيتين ومتاحَتين للعامة استُخدمتا فعليًا في التجارب الواردة بالبحث الثالث: ECW (بيانات أحمال الحوسبة الطرفية والسحابية) وSMD (بيانات مراقبة الخوادم واكتشاف الشذوذ). استخدم البحث الثالث السلاسل الزمنية متعددة المتغيرات لتدريب وتقييم نموذج TimesNet للتنبؤ، ثم مرّر التنبؤات إلى سياسة تفريغ مهام LinUCB داخل بيئة MEC محاكاة.

أما البحث الرابع فيجمع بين المحاكاة العددية ومنصة اختبار مادية تضم خوادم طرفية ولوحات NVIDIA Jetson. استخدم YOLOv5 لتوليد مهام كشف الصور، لكن الورقة لا تحدد مصدر مجموعة الصور نفسها ولا تنشرها؛ لذلك لا يجوز افتراض أنها COCO. الأبحاث الأول والثاني والخامس تعتمد على بيئات محاكاة وبيانات/أحمال مولّدة اصطناعيًا، ولا تحدد مجموعة بيانات خارجية حقيقية مستخدمة في التجارب.

1. تصنيف الأبحاث الخمسة

P1 — Chance constraint-based dependent task offloading

محاكاة فقط. تُولَّد عينات Monte Carlo اصطناعيًا لتدريب نماذج ANN؛ لا توجد مجموعة بيانات عامة محددة.

P2 — ESFMTO: reliable task offloading with edge-server failure model

محاكاة مخصصة لبيئة IIoT، تشمل أعطال الخوادم والحاويات والتعافي منها؛ لا توجد مجموعة بيانات حقيقية منشورة ومحددة.

P3 — Forecast-driven task offloading

يستخدم مجموعتي البيانات الحقيقيتين ECW وSMD لتنبؤ الأحمال ومؤشرات الأعطال، ثم يختبر التفريغ والموثوقية في محاكاة MEC.

P4 — QoE and Reliability-Aware Task Offloading

محاكاة عددية بالإضافة إلى منصة اختبار فعلية: 3 خوادم طرفية و12 لوحة NVIDIA Jetson وموجّه يعمل كمحطة أساسية. مجموعة الصور غير محددة.

P5 — RELTO

محاكاة MEC مخصصة باستخدام التعلم المعزز العميق؛ تنص الورقة على عدم استخدام بيانات فعلية في البحث.

2. مجموعات البيانات والأصول التجريبية

مجموعة أحمال الحوسبة الطرفية والسحابية | ECW — Edge Cloud Workload

- المصدر: سجلات تشغيل حقيقية من منصة تجارية متعددة المستأجرين للحوسبة الطرفية والسحابية، جمعها Huang وآخرون (2023). اسم الشركة غير معلن.
- الإصدارات المتاحة في المستودع: ECW-08 بحجم 797 × 720 × 16 وECW-09 بحجم 1,022 × 720 × 16. تمثل البيانات 1,309,680 ملاحظة خادم-ساعة إجمالًا، ولكل ملاحظة 16 خاصية.
- التغطية الزمنية: أغسطس 2022 لملف ECW-08 وسبتمبر 2022 لملف ECW-09. يذكر البحث نطاق أغسطس إلى أكتوبر، لكن المستودع الأساسي يعرض مصفوفتَي أغسطس وسبتمبر؛ لا نفترض وجود ملف أكتوبر.
- الخصائص: bw_upload، hour، day، week، province، bandwidth_type، nat_type، isp، billing_rule، upbandwidth، upbandwidth_base، cpu_num، memory_size، disk_size، test_sat، loss_sat.

• الصيغة: NumPy (.npy)، مع ملفات مشتقة بصيغة .pkl. الاستخدام: التنبؤ بديناميكيات أحمال/رفع البيانات عبر TimesNet، ثم الاستفادة من التنبؤات في سياسة تفريغ المهام.

• الترخيص: المستودع عام، لكن ملف README لا يذكر ترخيصًا صريحًا لمجموعة البيانات. يجب تأكيد شروط إعادة الاستخدام قبل إعادة التوزيع أو الاستخدام التجاري.

• المستودع: https://github.com/hsy23/ECWDataset

• تحميل أغسطس: https://raw.githubusercontent.com/hsy23/ECWDataset/main/ECW_08.npy

• تحميل سبتمبر: https://raw.githubusercontent.com/hsy23/ECWDataset/main/ECW_09.npy

مجموعة بيانات مراقبة الخوادم | SMD — Server Machine Dataset

• المصدر: جمعها مؤلفو OmniAnomaly من شركة إنترنت كبيرة. تتكون من 28 خادمًا/آلة و38 متغيرًا لكل آلة، وتمتد على خمسة أسابيع.

• الحجم: 708,405 صفوف تدريب + 708,420 صف اختبار = 1,416,825 صفًا إجمالًا عبر الآلات الـ28. يحافظ المصدر الأصلي على التقسيم لكل آلة.

• الخصائص: 38 قياسًا متعدد المتغيرات لمراقبة الخوادم، مع test_label لتحديد الشذوذ وinterpretation_label لتحديد الأبعاد المرتبطة به. لا تسرد الورقة أو README أسماء المتغيرات الـ38 بالتفصيل.

• الصيغة: ملفات نصية رقمية لكل آلة للتدريب والاختبار والتسميات. الفاصل الزمني الدقيق بين العينات غير محدد في README الأصلي؛ لذلك لا نعتمد ادعاء الدقيقة الواحدة الوارد في بعض النسخ غير الأصلية.

• الاستخدام في البحث الثالث: الاستفادة من تسميات الشذوذ لبناء مؤشر أحداث الأعطال وشدة الأعطال، ثم التنبؤ بها باستخدام TimesNet وإدخال معدل الخطر المتوقع في نموذج موثوقية MEC.

• الترخيص: المستودع متاح للعامة، لكن ترخيص البرنامج لا يثبت تلقائيًا حقوق إعادة استخدام بيانات القياس المأخوذة من الشركة. يجب التحقق من شروط البيانات نفسها.

• المستودع: https://github.com/NetManAIOps/OmniAnomaly

• تحميل المستودع ZIP: https://github.com/NetManAIOps/OmniAnomaly/archive/refs/heads/master.zip

أصل YOLOv5 في البحث الرابع — ليس مجموعة بيانات منشورة

استخدم البحث نماذج YOLOv5n وYOLOv5s وYOLOv5m وYOLOv5l ودقات صور 640 و960 و1280 و1600 لتكوين مهام كشف الصور على منصة الاختبار. لم يذكر مصدر الصور أو عددها أو ترخيصها أو رابط تنزيلها. YOLOv5 برنامج/كاشف وليس اسم مجموعة الصور. لا تفترض أن الصور من COCO. المستودع البرمجي: https://github.com/ultralytics/yolov5

3. ملخص إعدادات المحاكاة

• P1: بنية Cloud–Edge–End وثلاث شبكات لاسلكية؛ 30 مهمة لكل تطبيق مع علاقات اعتماد DAG واحتمال اعتماد ρ=0.8. تُسحب خصائص المهام عشوائيًا من نطاقات Table 3. تردد المعالجة: الهاتف 7GHz، الطرف 15GHz، السحابة 30GHz؛ حجم الإدخال 500–4,000KB؛ النطاق الصاعد 8–16MHz والهابط 10–20MHz. تُولَّد عينات Monte Carlo، لكن العدد المستهدف والبذور ومدة المحاكاة غير مذكورة.

• P2: محاكاة IIoT تضم 20 خادمًا طرفيًا و50–70 مستخدمًا؛ كل مستخدم يولد مهمة في كل فترة زمنية. أحجام المهام المختبرة 1–5MB. معدل فشل العتاد 0.02–0.05 ومعدل فشل الحاوية 0.03–0.09، مع نمذجة التعافي والتأخير. لا يذكر البحث منصة محاكاة عامة أو مدة الفترة أو عدد الحاويات/الحلقات.

• P3: بيئة MEC ثلاثية الطبقات تضم افتراضيًا 10 أجهزة مستخدم و5 خوادم طرفية وسحابة. تردد المعالجة: جهاز المستخدم 0.8GHz، الطرف 8–12GHz، السحابة 40GHz؛ عرض النطاق 30MHz؛ قدرة الإرسال 0.25W. بيانات ECW وSMD حقيقية، لكن تنفيذ التفريغ وسيناريو الأعطال محاكاة. استخدمت التجارب 30 بذرة عشوائية في تجارب التوسع و5 بذور لاختبار الخصائص.

• P4: المحاكاة: محطة أساسية واحدة وثلاثة خوادم طرفية، مع 20 أو 35 أو 50 جهازًا محمولًا. منصة الاختبار: 3 خوادم و12 لوحة Jetson وموجّه. عرض النطاق 15/25/35MHz، ومعالجات الأجهزة المحمولة 1.0–1.2GHz، وسعات الخوادم الطرفية في ثلاث فئات. لم تُنشر سجلات المهام الخام أو مجموعة الصور.

• P5: مساحة 5,000 × 5,000 متر؛ 50–250 مستخدمًا و4–32 خادمًا طرفيًا؛ كل مستخدم ينشئ أربع مهام. تردد المعالجة المحلي 10^8 دورة/ثانية والطرفي 10^7–10^10 دورة/ثانية؛ عرض النطاق 20–500MHz. اختُبرت معدلات فشل الإرسال والحوسبة عند 0.02 و0.04 و0.06 و0.08. لا توجد بيانات فعلية أو مدة تجارب/بذور معلنة.

4. التوصيات

• الأولوية الأولى — ECW: أفضل مصدر عام لتمثيل ديناميكيات أحمال الحوسبة الطرفية وخصائص الخادم والشبكة. لكنه لا يحتوي على نتائج تفريغ على مستوى المهمة أو مخططات اعتماد المهام أو تسميات زمن التنفيذ؛ لذلك لا يكفي وحده لتقييم نظام offloading كامل.

• الأولوية الثانية — SMD: مناسب لإشارات صحة الخادم والشذوذ والموثوقية. لكنه ليس سجل حزم شبكية ولا مجموعة مهام MEC. يلزم توضيح منهجي لتحويل تسميات الشذوذ إلى شدة أعطال خادم طرفي مع الحفاظ على هوية كل آلة.

• فرصة مهمة — بيانات منصة اختبار البحث الرابع: اطلب من المؤلفين مصدر الصور وترخيصها وإصدار YOLOv5 وسجلات زمن التنفيذ والطاقة والإكمال لكل تجربة وتفاصيل القياس على العتاد الحقيقي.

• استخدم مواصفات المحاكاة في P1 وP2 وP5 لاستكمال سيناريوهات المهام التابعة والأعطال والحاويات والازدحام، مع إبقاء البيانات الاصطناعية منفصلة بوضوح عن القياسات الواقعية.

5. نقاط يجب تأكيدها قبل اعتماد البيانات

• ECW: ما الملفات والفهارس الزمنية التي استخدمها البحث تحديدًا؟ ولماذا يذكر أغسطس–أكتوبر بينما المستودع الأساسي يعرض أغسطس وسبتمبر؟ وما شروط الترخيص وإعادة الاستخدام؟

• SMD: كيف جرى تحويل بيانات الآلات الـ28 إلى سلسلة أحداث/شدة أعطال؟ وما التقسيم الزمني المستخدم في TimesNet؟

• P4: ما مصدر الصور وترخيصها؟ وما إصدار YOLOv5؟ وهل يمكن مشاركة سجلات زمن التنفيذ والطاقة ونجاح تنفيذ المهام؟

• P1 وP2 وP5: اطلب الشيفرة، والبذور العشوائية، وعدد التكرارات، ومدة التجربة، وتفاصيل توزيع توليد المهام والنتائج الخام.

ملاحظة منهجية مهمة

تمت مراجعة الأبحاث الخمسة المحددة فقط. لا تُعد المهام المولدة بالمحاكاة بيانات واقعية. لم يتم إنشاء Dataset v0 أو دمج البيانات أو تنظيفها أو تدريب أي نموذج ضمن هذا العمل. كما لم يتم افتراض أن مجموعة صور البحث الرابع هي COCO، ولم يتم اعتبار ملفات البرنامج ترخيصًا تلقائيًا للبيانات.

النسخة الإنجليزية الكاملة تلي هذا القسم في بداية المستند؛ وتبقى الروابط والمراجع الأصلية كما وردت في التقرير.

5. Objectives, Dataset, Research Gaps & Integration — Paper-by-Paper

This section adds a focused research interpretation for each of the five papers. “Integration” means how the paper’s method or evidence can be incorporated into a future IoT/Edge Computing/Task Offloading study; it does not claim that the papers themselves performed this integration.

P1 — Chance constraint-based dependent task offloading for multi-access edge computing under uncertainty

Objective: Develop a chance-constrained offloading framework for dependent tasks in multi-access edge computing (MEC), accounting for uncertainty in wireless/network conditions and task execution. The method uses an ANN surrogate to estimate uncertain outcomes and supports offloading decisions while respecting probabilistic constraints.

Dataset: No named public or real-world dataset is used. The authors generate synthetic Monte Carlo samples from the task/network parameter ranges in Table 3 and use them to train ANN models. The scenario includes 30 dependent tasks, a DAG dependency structure (ρ = 0.8), and three wireless networks in a cloud–edge–end architecture.

Research gap: The evaluation relies on generated samples and assumed parameter distributions rather than traces from a deployed MEC/IoT environment. The paper does not provide a public dataset, and the exact Monte Carlo sample count and full raw traces are not reported. This limits independent reproduction and evidence of robustness under real workload drift.

Integration into our research: Use ECW to supply realistic edge-cloud workload and bandwidth dynamics instead of relying only on uniform synthetic task/network inputs. Use SMD anomaly labels to introduce time-varying server-risk conditions. Preserve the paper’s DAG/dependent-task and chance-constraint formulation, then compare synthetic-only results against real-trace-driven scenarios. A separate task-DAG generator will still be needed because ECW/SMD do not provide task dependencies.

الهدف (Objective): تطوير إطار لتفريغ المهام التابعة باستخدام قيود احتمالية (Chance Constraints) في بيئة الحوسبة الطرفية متعددة الوصول، مع أخذ عدم اليقين في الشبكة وتنفيذ المهام في الاعتبار. يستخدم البحث نموذج ANN بديلًا لتقدير النتائج غير المؤكدة ودعم قرارات التفريغ مع الالتزام بالقيود الاحتمالية.

مجموعة البيانات (Dataset): لا يستخدم البحث مجموعة بيانات عامة أو واقعية محددة. ينشئ الباحثون عينات اصطناعية من نطاقات خصائص المهام والشبكة الموضحة في Table 3 لتدريب نماذج ANN. يتضمن السيناريو Monte Carlo وثلاث شبكات لاسلكية ضمن بنية Cloud–Edge–End. باحتمال اعتماد ρ = 0.8 DAG 30 مهمة مترابطة في

الفجوة البحثية (Research Gap): يعتمد التقييم على عينات مولدة وتوزيعات مفترضة بدلًا من سجلات تشغيل حقيقية لبيئة MEC/IoT. لا يوفر البحث Dataset عامة، كما لا يحدد العدد النهائي لعينات Monte Carlo ولا ينشر السجلات الخام كاملة؛ وهذا يقلل من سهولة إعادة التجربة والتحقق من الأداء مع تغير الأحمال الواقعية.

كيفية الدمج في بحثنا (Integration): يمكن استخدام ECW لإدخال أحمال واقعية وتغيرات فعلية في نطاق الشبكة الطرفية بدل الاعتماد فقط على مدخلات اصطناعية موزعة بانتظام. ويمكن استخدام تسميات الشذوذ في SMD لمحاكاة تغير مخاطر أعطال الخوادم بمرور الوقت. نحافظ على نموذج DAG والقيود الاحتمالية في البحث، ونقارن النتائج بين سيناريو اصطناعي وآخر مدفوع ببيانات واقعية. ستظل هناك حاجة إلى مولّد مستقل لعلاقات اعتماد المهام؛ لأن DAG لا يحتويان على SMD وECW للمهام.

P2 — ESFMTO: A reliable task offloading strategy based on edge server failure model in IIoT

Objective: Propose a reliability-aware task-offloading strategy for Industrial IoT (IIoT) that explicitly models edge-server hardware failures, container failures, and recovery processes. The goal is to improve task completion/reliability while accounting for communication, queueing, and computation delays.

Dataset: No named real-world dataset or public benchmark is reported. Experiments use a custom IIoT simulation with 20 edge servers and 50–70 users; each user generates one task per time slot. Task sizes are varied (1–5 MB), and hardware/container failure and recovery behavior is generated using the paper’s assumed stochastic parameters.

Research gap: The failure and recovery processes are parameterized in simulation, but the paper does not validate them against real edge-server/container incident logs. The simulator implementation, slot duration, container count, run/episode count, and raw generated traces are not fully specified or released, which makes exact reproduction difficult.

Integration into our research: Use SMD as an empirical source of server anomaly/failure signals to calibrate or stress-test the server-failure component. Use ECW to represent realistic edge-server capacity and workload variation. Extend the simulation

with container-level failure events as a separate synthetic layer, clearly labeling which variables are measured (SMD/ECW) and which are simulated. Compare the paper's assumed failure rates with rates inferred from the selected telemetry after careful mapping.

(Objective): الهدف اقتراح استراتيجية لتفريغ المهام تراعي الموثوقية في بيئة إنترنت الأشياء الصناعية IIoT، مع نمذجة أعطال عتاد الخوادم الطرفية وأعطال الحاويات وعمليات التعافي. الهدف هو تحسين إكمال المهام وموثوقيتها مع مراعاة تأخير الاتصال والانتظار والمعالجة.

(Dataset): لا يذكر البحث Dataset واقعية أو Benchmark عامة محددة. تعتمد التجارب على محاكاة مجموعة البيانات مخصصة تضم 20 خادمًا طرفيًا و50–70 مستخدمًا، وينشئ كل مستخدم مهمة في كل فترة زمنية. تتغير أحجام المهام بين 1 و5 MB، وتُولد الأعطال والتعافي وفق معاملات احتمالية مفترضة في البحث.

(Research Gap): الفجوة البحثية تُحدد عمليات الفشل والتعافي بمعاملات داخل المحاكاة، لكن البحث لا يتحقق منها باستخدام سجلات حقيقية لأعطال الخوادم أو الحاويات الطرفية. كما أن تنفيذ المحاكي ومدة الفترة وعدد الحاويات وعدد مرات التشغيل والسجلات الخام ليست موضحة أو منشورة بالكامل؛ مما يصعّب إعادة التجربة بدقة.

(Integration): كيفية الدمج في بحثنا كمصدر تجريبي لإشارات الشذوذ ومؤشرات صحة الخادم SMD يمكن استخدام لتمثيل تغير أحمال الخوادم وسعاتها بصورة ECW من أجل معايرة أو اختبار جزء أعطال الخوادم. ويمكن استخدام أقرب للواقع. نضيف أحداث أعطال الحاويات كطبقة اصطناعية منفصلة، مع توضيح المتغيرات المقاسة من والمتغيرات المولدة بالمحاكاة. ثم نقارن معدلات الفشل المفترضة في البحث بالمعدلات المستنتجة من SMD/ECW البيانات بعد وضع طريقة تحويل منهجية.

P3 — Forecast-driven task offloading for reliable and adaptive mobile edge computing

Objective: Build a forecast-driven and adaptive MEC offloading framework. TimesNet predicts workload and failure-related time-series behavior from real datasets; the forecasts are then used as context for a LinUCB-based offloading policy to improve adaptation and reliability under changing conditions.

Dataset: Two real-world datasets are used: (1) ECW (Edge Cloud Workload), operational edge-cloud telemetry with monthly arrays ECW-08 and ECW-09 and 16 features; (2) SMD (Server Machine Dataset), five-week telemetry from 28 machines with 38 channels and anomaly labels. These support forecasting of workload and failure-related signals. Offloading itself is evaluated in a simulated three-tier MEC environment.

Research gap: The real datasets are not native task-offloading datasets: ECW does not provide per-task DAGs, offloading decisions, execution outcomes, or end-to-end latency; SMD is server telemetry rather than MEC/container incident logs. The paper's downstream mapping from anomaly labels to failure-event/intensity signals and its exact dataset split are not fully detailed. Data availability is stated as "on request" despite the existence of public source repositories.

Integration into our research: Treat this paper as the strongest baseline for a real-data-driven approach. Reuse ECW for workload/bandwidth forecasting and SMD for anomaly/failure forecasting, but add a documented mapping layer from server anomalies to edge-server reliability. Add a separate task-level dataset or controlled DAG/task generator to supply task size, CPU cycles, deadline, dependency, and completion outcome. Evaluate chronological train/validation/test splits and test generalization across months, machines, and changing load regimes.

(Objective): الهدف بناء إطار لتفريغ المهام في MEC يعتمد على التنبؤ والتكيف. يتنبأ TimesNet بسلوك الأحمال ومؤشرات الأعطال باستخدام بيانات حقيقية، ثم تُستخدم التنبؤات كسياق لسياسة تفريغ تعتمد على LinUCB لتحسين التكيف والموثوقية عند تغير ظروف النظام.

(Dataset): مجموعة البيانات لقياسات تشغيل الحوسبة الطرفية ECW يستخدم البحث مجموعتي بيانات واقعيتين: (1) ECW-09و ECW-08 والسحابية، وتشمل مصفوفتَي لقياسات خمسة أسابيع من 28 آلة و38 SMD و16 خاصية؛ (2) متغيرًا لكل آلة، مع تسميات للشذوذ. تُستخدم البيانات للتنبؤ بالأحمال وإشارات الأعطال، بينما يتم تقييم التفريغ ثلاثية الطبقات MEC داخل محاكاة.

(Research Gap): الفجوة البحثية لا يحتوي على ECW المجموعتان ليستا مجموعتي بيانات أصليتين لتفريغ المهام DAG: عبارة عن قياسات خوادم وليست SMDلكل مهمة أو قرارات التفريغ أو نتائج التنفيذ أو التأخير من البداية للنهاية؛ و مباشرة. كما أن تحويل تسميات الشذوذ إلى أحداث/شدة أعطال وتقسيم البيانات MEC/سجلات أعطال حاويات

المستخدم لاحقًا غير موضحين بالكامل. وتذكر الورقة أن البيانات متاحة عند الطلب رغم وجود مستودعات عامة للمصادر الأصلية.

Integration: يمكن اعتماد البحث كأقوى نقطة بداية لنهج يعتمد على بيانات حقيقية. نستخدم SMD للتنبؤ بالشذوذ والأعطال، مع إضافة خطوة موثقة لتحويل شذوذ الخوادم للتنبؤ بالأحمال وعرض النطاق، و ECW مستقلة على مستوى المهمة أو مولّد مضبوط للمهام التابعة Dataset إلى موثوقية للخادم الطرفي. ونحتاج إلى CPU لتوفير حجم المهمة ودورات والموعد النهائي والاعتماد ونتيجة التنفيذ. يجب استخدام تقسيم زمني Train/Validation/Test واختبار التعميم بين الشهور والآلات وأنماط الحمل المختلفة.

P4 — Quality of Experience and Reliability-Aware Task Offloading and Scheduling for Multi-User Mobile-Edge Computing Systems

Objective: Design a multi-user task-offloading and scheduling approach that jointly considers Quality of Experience (QoE) and reliability. The work evaluates performance through numerical simulations and a physical testbed consisting of three edge servers, twelve NVIDIA Jetson boards, and a router acting as the base station.

Dataset: No named public dataset is identified. The simulation generates task inputs and system conditions. The physical testbed uses image-detection workloads generated/executed with YOLOv5 variants (n/s/m/l) at several image resolutions. The paper does not identify the underlying image collection, its size, format, source, or license, and does not publish a task-level measurement dataset.

Research gap: The real-hardware experiment increases practical credibility, but the image dataset provenance and raw measurements are not sufficiently documented for independent reuse. There is no public dataset of per-task latency, energy, reliability, QoE, or offloading outcomes. YOLOv5 is software, not the underlying image dataset; the paper does not confirm COCO.

Integration into our research: Use the testbed design as a reference for a physical validation stage. Request or reproduce logs containing task input size, model/resolution, device/server identity, execution time, energy, success/failure, and offloading decision. Pair these measurements with ECW for background edge load and SMD only for server-health context. If image workloads are recreated, select a clearly licensed image dataset and document it separately from YOLOv5; do not assume the paper used COCO.

Objective: الهدف تصميم أسلوب لتفريغ وجدولة المهام لعدة مستخدمين يراعي في الوقت نفسه جودة التجربة وموثوقية التنفيذ. يقيّم البحث الأداء من خلال محاكاة عددية ومنصة اختبار فعلية تضم ثلاثة خوادم طرفية و12 QoE وموجّهًا يعمل كمحطة أساسية NVIDIA Jetson لوحة.

Dataset: مجموعة البيانات لا يحدد البحث Dataset عامة بالاسم. تُولد مدخلات المهام وظروف النظام داخل المحاكاة. أما منصة الاختبار فتستخدم مهام كشف الصور التي تُنفذ باستخدام إصدارات YOLOv5 (n/s/m/l) ودقات صور لقياسات كل مهمة Dataset متعددة. لا يحدد البحث مصدر مجموعة الصور أو حجمها أو صيغتها أو ترخيصها، ولا ينشر.

Research Gap: الفجوة البحثية تضيف تجربة العتاد الحقيقي مصداقية عملية، لكن مصدر صور الاختبار والقياسات عامة تتضمن زمن تنفيذ كل مهمة والطاقة Dataset الخام غير موثقين بما يكفي لإعادة الاستخدام المستقل. لا توجد برنامج وليس مجموعة الصور نفسها، كما أن البحث لا يؤكد YOLOv5 وقرار التفريغ. يجب التأكيد أن QoEوالموثوقية و استخدام COCO.

Integration: يمكن استخدام تصميم منصة الاختبار كمرجع لمرحلة تحقق مادي في مشروعنا. كيفية الدمج في بحثنا يجب طلب أو جمع سجلات تتضمن حجم المهمة والنموذج/الدقة وهوية الجهاز والخادم وزمن التنفيذ والطاقة SMD لتمثيل الحمل الخلفي على الخوادم، واستخدام ECW والنجاح/الفشل وقرار التفريغ. يمكن ربط القياسات مع فقط كسياق لصحة الخادم. وإذا أعدنا إنشاء مهام الصور، نختار مجموعة صور بترخيص واضح ونوثقها منفصلة عن COCO. ولا نفترض أن البحث استخدم YOLOv5، برنامج.

P5 — RELTO: A reliability-oriented DRL approach with context-aware adaptive reward weighting for multi-objective task offloading in MEC

Objective: Propose a reliability-oriented deep reinforcement learning (DRL) approach for multi-objective MEC task offloading. RELTO uses context-aware adaptive reward weighting to balance objectives such as task delay, energy/resource cost, and reliability under varying user density, server capacity, bandwidth, and failure probabilities.

Dataset: No real-world dataset is used. The paper's data-availability statement says no data was used. Results are generated by a custom MEC simulation: 50–250 users, 4–32 edge servers, four tasks per user, synthetic task arrivals, bandwidth and CPU ranges, and assumed transmission/computation failure probabilities. PPO is used for learning.

Research gap: The method is assessed in a fully synthetic environment and has no external real-world workload or failure trace validation. Simulation duration, random seeds/replications, and raw traces are not reported in sufficient detail. Therefore, it is unclear how robust the learned policy is under real edge-cloud workload patterns and empirically observed failures.

Integration into our research: Use ECW to drive time-varying workload and bandwidth/resource context, and SMD to introduce empirically grounded anomaly/failure signals. Retain RELTO's adaptive reward-weighting DRL design, but compare training on synthetic-only data with training or evaluation under trace-driven scenarios. Add task-level attributes and outcomes through a documented generator or a separate task dataset. Report seeds, episode counts, simulation duration, and chronological/generalization tests.

الهدف (Objective): اقتراح أسلوب تعلم معزز عميق DRL في مهام متعددة الأهداف يركز على الموثوقية لتفريغ MEC. يستخدم RELTO أوزان مكافأة تكيفية تراعي سياق النظام للموازنة بين التأخير والطاقة/تكلفة الموارد والموثوقية مع تغير عدد المستخدمين وسعة الخوادم وعرض النطاق واحتمالات الفشل.

مجموعة البيانات (Dataset): لا يستخدم البحث بيانات واقعية؛ وينص قسم إتاحة البيانات على عدم استخدام بيانات مخصصة تضم 50–250 مستخدمًا و4–32 خادمًا طرفيًا وأربع مهام لكل MEC في البحث. تُولد النتائج من محاكاة للتعلم PPO وعرض نطاق واحتمالات فشل مولدة اصطناعيًا. يستخدم البحث CPU مستخدم، مع وصول مهام وموارد.

الفجوة البحثية (Research Gap): يُقيّم الأسلوب في بيئة اصطناعية بالكامل دون التحقق باستخدام سجلات أحمال أو أعطال واقعية. كما أن مدة المحاكاة والبذور العشوائية وعدد مرات التكرار والسجلات الخام غير موضحة بما يكفي. لذلك لا يتضح مدى ثبات السياسة المتعلمة عند مواجهة أنماط أحمال طرفية حقيقية وأعطال مرصودة فعليًا.

كيفية الدمج في بحثنا (Integration): يمكن استخدام ECW لتوفير تغيرات واقعية في الأحمال وعرض النطاق والموارد، واستخدام SMD لإضافة مؤشرات شذوذ وأعطال مستندة إلى قياسات حقيقية. نحافظ على تصميم DRL وأوزان المكافأة التكيفية في RELTO، لكن نقارن التدريب على بيانات اصطناعية فقط بالتدريب أو التقييم في سيناريوهات مستقلة للمهام. يجب Dataset مدفوعة بسجلات واقعية. ونضيف خصائص ونتائج المهام من خلال مولّد موثق أو الإبلاغ عن البذور وعدد الحلقات ومدة المحاكاة واختبارات التعميم الزمني.